

K-MENU VOICE GUIDE

영어권 관광객을 위한 한국 음식 멀티모달 음성 가이드

SDD MVP 기획서 · 2차 수정본 v0.3

항목	내용
프로젝트	KDT AI Human 7기 1차 프로젝트 · 나만의 음성모델 만들기
팀 구성	팀 C · 하정운, 박민영, 배재훈, 차백호 (4명)
개발 기간	14일
가용 자원	노트북 RTX 5060 1대 · 원격 데스크톱 RTX 3080 Ti 12GB · 필요 시 Colab
주제 유형	유형 2 · 입력 조건에 따른 조건부 TTS

본 문서는 팀 검토를 위한 MVP 기획서이며, 모델 기술검증 결과와 팀 합의에 따라 계속 수정될 수 있다.

1. 프로젝트 한 줄 정의

영어권 외국인 관광객이 한국어 메뉴판을 촬영하고 영어 음성으로 질문하면, 음식의 특징·재료·맵기를 이해하기 쉬운 영어 음성으로 설명해주는 멀티모달 한국 음식 가이드. 기존 번역 서비스가 '글자를 옮기는 것'에 그치는 것과 달리, 대화형 음성 설명으로 '문화적 맥락'까지 전달하는 것이 차별점이다.

- 프로젝트 유형: 유형 2 — 입력 조건에 따른 TTS 음성 변화
- 핵심 학습 대상: 딥러닝 TTS 모델 (비교실험을 거쳐 확정 예정 — 현재 검토 후보: Qwen3-TTS 0.6B Base, XTTS-v2)
- 가산점 요소: Vision/OCR
- 개발 기간: 14일
- 팀원: 하정운·박민영·배재훈·차백호, 총 4명

2. 사용자 분석

사용자 특성

- 영어를 사용하는 외국인 개별 관광객
- 한국 음식과 한국어 메뉴에 익숙하지 않은 사람
- 번역 앱은 사용할 수 있지만 한국 음식의 문화적 의미나 특징은 모르는 사람

사용 상황

- 소규모 한식당이나 전통시장에서 한국어 메뉴판을 확인하는 상황
- 음식 사진이나 영어 설명이 부족한 상황
- 직원과 영어로 충분히 소통하기 어려운 상황

문제 상황 · 기존 방식의 한계

이미지 번역으로 음식명을 영어로 변환해도 음식의 주요 재료, 맛과 맵기, 조리 형태, 먹는 방법, 한국어 발음을 충분히 알기 어렵다. 기존 번역 서비스는 메뉴 글자를 번역하고 읽어줄 수 있지만, 번역 결과가 음식의 실제 특징까지 설명해주지는 않는다.

곱창전골 → Beef intestine hot pot

번역은 되었지만 맛·조리 방식·먹는 방법은 여전히 알기 어렵다.

한국관광 데이터랩에 소개된 제주 외국인 소비 분석에서는 외국인 관광객의 80% 이상이 한식 음식점에서 소비한 것으로 나타났고, 주문 과정의 언어 불편을 줄이기 위한 다국어 메뉴판 사업도 추진됐다.


3. 문제 정의

한국 음식에 익숙하지 않은 영어권 개별 관광객은 한국어 메뉴판을 번역하더라도 음식의 재료·맛·맵기·먹는 방법을 충분히 이해하기 어려워 메뉴 선택에 불편을 겪으므로, 메뉴를 촬영하고 영어 음성으로 질문하면 필요한 음식 정보를 이해하기 쉬운 음성으로 설명해주는 서비스가 필요하다.

왜 번역 앱만으로는 부족한가 — 유사 서비스 조사

방한 외국인 관광객은 2023년 1,103만 명에서 2025년 1,893만 명으로 증가했다. 이 수요를 대상으로 한 기존 서비스들을 조사한 결과, 아래와 같이 전부 '텍스트/이미지 번역'에 초점이 맞춰져 있었다.

방한 외국인 관광객 수 (단위: 만 명)



서비스	특징	출처
캐치테이블 영어버전	K-푸드 소개 기능 포함, 외국인 관광객 대상 레스토랑 예약	hotelrestaurant.co.kr
‘맛말’ (글나무)	제주관광공사 지원, QR코드 기반 외국어 메뉴판	traveli.net
플리토 메뉴번역앱	12개 언어 지원 (한국어·영어·중국어 간체/번체·일본어 등)	menutranslatorapp.com
초기 메뉴번역기 앱 (2014)	카메라로 메뉴판을 비추면 자동 번역	asiae.co.kr
관광객 통계	방한 외국인 2023년 1,103만 → 2025년 1,893만 명	한국관광 데이터랩

※ 출처 URL 전체 목록은 팀 공유 문서(data_초안.md)에 별도 정리돼 있으며, 발표자료에는 QR코드 또는 각주로 링크를 첨부한다.

결론: 위 서비스들은 '글자를 다른 언어로 옮기는 것'까지만 하고, '재료·맛·맵기·먹는 법을 음성으로 설명'하는 대화형 서비스는 확인되지 않았다. 이것이 K-Menu Voice Guide의 핵심 차별점이다.

4. SDD Spec

Why

한국 음식과 한국어 메뉴에 익숙하지 않은 영어권 개별 관광객은, 한국어를 읽지 못하고 낯선 음식·매운 음식을 선택하는 데 부담을 느끼며, 식당 직원에게 직접 영어로 물어보는 것도 어려워한다.

소규모 한식당에서는 메뉴판에 한글 음식명과 가격만 표시된 경우가 많다. 번역 앱으로 음식명을 번역해도 음식의 형태·맛·재료를 이해하기 어려워, 결국 익숙한 메뉴만 반복해서 선택하게 된다.

- 직역만으로 한국 음식을 이해하기 어려움
- 음식마다 별도의 웹 검색이 필요함
- 직원과 영어로 소통하기 어려움
- 음식명의 한국어 발음을 알기 어려움

Goal

MVP 기능 범위

- 지원 언어: 영어 1개
- 지원 음식: 한국 대표 음식 30개
- 음성 질문 유형: n개 (개발 단계에서 실제 커버 가능한 범위에 맞춰 조정)
- TTS 스타일: GUIDE-CAUTION 2개
- 입력 방식: 메뉴 사진 촬영(Vision/OCR) + 영어 음성 질문(STT) — 사진 한 장짜리 서비스가 아니라 음성 질의응답이 핵심인 멀티모달 서비스
- 배포 형태: 웹앱 — 브라우저 접속 후 모바일 홈 화면에 추가해 앱처럼 사용 가능

영역	MVP 목표
메뉴 이미지 테스트	50장 이상
등록 음식명 인식률	90% 이상
영어 음성 질문 테스트	50개 이상
질문 의도 분류 정확도	92% 이상 (규칙 기반, 미달 시 분류모델 Plan B)
질문 종료 후 음성 재생 시작	평균 7초 이내
TTS 외부 평가자	5명 이상
GUIDE-CAUTION 스타일 구분률	85% 이상
음식명 발음 평가	기본 모델 대비 평균 0.4점 이상 향상
외부 사용성 테스트	5명 이상
작동 가능한 배포 웹앱	1개 (1안 HF Spaces·ZeroGPU 우선, 2안 원격서버 백업)

수치는 목표이며, 최종 발표에서는 달성 여부를 그대로 공개한다.

이번 MVP Out of Scope

- 등록되지 않은 모든 한국 음식 설명
- 실시간 동영상 OCR 및 손글씨 메뉴 완벽 인식
- 식당 주문·결제·예약
- 직원과의 실시간 통역
- 사용자 음식 등록 기능

향후 확장 로드맵

아래 항목들은 '안 하는 것'이 아니라, 이번 14일 MVP 범위 밖에 있는 '다음 단계 목표'로 관리한다.

- 영어 이외의 다국어 지원
- 영양학적·의학적 판단을 포함한 알레르기 안전성 보장
- 자유로운 AI 대화 (외부 LLM API 기반 — 2차 프로젝트 영역과 연계)
- Flutter 기반 모바일 앱

What — 정상 흐름

- 1. 사용자가 메뉴판을 촬영하거나 사진을 업로드한다.
- 2. Vision/OCR이 메뉴판의 한국어 글자를 추출한다.
- 3. 등록된 30개 음식명과 OCR 결과를 문자열 유사도(RapidFuzz)로 비교한다.
- 4. 인식된 음식 목록을 보여주고 사용자가 하나를 선택한다.
- 5. 사용자가 영어 음성으로 질문한다.
- 6. STT가 음성을 영어 텍스트로 변환한다 — 이 서비스의 입력은 사진 한 장이 아니라 '사진+음성' 두 가지다.
- 7. 규칙 기반 로직이 질문을 의도별로 분류한다 (Plan B: 목표 미달 시 분류모델 검토).
- 8. 음식 데이터베이스에서 해당 설명을 가져온다.
- 9. 질문 종류에 따라 GUIDE 또는 CAUTION 조건을 선택한다.
- 10. 파인튜닝 TTS가 영어 설명 음성을 생성한다.
- 11. 영어 텍스트와 음성을 함께 출력한다.

How — 전체 파이프라인

메뉴 이미지 → OpenCV 전처리 → 한국어 OCR(PaddleOCR) → 문자열 유사도 매칭(RapidFuzz) → 음식 선택 → 영어 음성 질문(마이크 입력) → Faster-Whisper(STT) → 규칙 기반 의도 분류 → 음식 설명 JSON → GUIDE/CAUTION 조건 → 파인튜닝 TTS → 영어 텍스트 + 음성 출력

데이터 소스

AI Hub '관광 음식메뉴판 데이터'를 참고 자료로 활용한다. 이미지 100,113장(12개 업종, 한식 28.1%), JSON 라벨에 음식명·분류·가격·재료 정보와 영어 등 4개국어 번역이 포함돼 있다. 한식 카테고리 필터링해 100~200장을 확보한 뒤 그중 상태가 좋은 50장 이상을 선별해 테스트에 사용한다. '맛·먹는 법' 같은 서술형 설명은 데이터셋에 없어 팀이 직접 조사해 보완한다.

Vision/OCR

- OpenCV로 회전·대비·크기 보정
- PaddleOCR로 한국어 글자 추출 (EasyOCR 대비 실무 비교 우수, 109개 언어 지원)
- RapidFuzz로 OCR 결과와 등록 음식명 유사도 비교 (문자열 유사도, 임베딩 아님)
- Vision 모델 자체는 파인튜닝하지 않음 (학습을 안 하므로 데이터 증강도 불필요)
- 메뉴 사진 50장 이상으로 인식 성능 평가

STT — 이 서비스의 두 번째 축

사용자 입력은 '사진 한 장'이 아니라 '사진 + 음성 질문' 두 가지로 구성된다. STT는 사용자의 실제 목소리로 한 질문을 텍스트로 바꾸는, Vision/OCR과 동등한 비중의 핵심 파이프라인이다.

- 1차 후보: Faster-Whisper small.en
- 비교 후보: Whisper base.en
- 동일한 영어 발화 50개로 CER/WER·속도 비교
- 최종 선택 기준: 질문 인식 정확도, 실행 속도, 전체 지연시간

질문 분류

외부 LLM API를 사용하지 않고 키워드와 정규표현식으로 질문 의도를 분류한다. 매칭되지 않으면 지원 질문 예시를 표시한다.

Plan B

1차는 규칙 기반 그대로 진행한다. 실제 테스트에서 목표 정확도에 크게 못 미칠 경우에만, 소형 텍스트 분류 모델(BERT 계열) 파인튜닝으로 교체를 검토한다 — GPU·일정 리스크가 이미 TTS 파인튜닝에 집중돼 있어, 검증되지 않은 상태로 새 학습 파이프라인을 먼저 추가하지 않는다.

TTS 모델

구분	모델	사용 계획
1차 후보	Qwen3-TTS 0.6B Base	12GB 환경에서 2일 차까지 추론·학습 가능성 검증
비교·대체	XTTS-v2	동일 문장 기본 성능 비교, 필요 시 공식 Colab 파인튜닝 경로 활용

두 모델 모두 아직 팀이 직접 비교실험을 진행하지 않은 ‘검토 후보’이며, 2일 차 기술검증 결과에 따라 최종 모델을 확정한다.

XTTS-v2의 12GB 파인튜닝 가능 조건은 윈도우 기준이며, 리눅스 환경은 16GB 이상을 권장한다는 점이 조사에서 확인됐다. 원격 데스크톱의 OS를 확인한 뒤, 대체안으로서의 실현 가능성을 재검증한다.

TTS 학습 대상

- 영어 문장 속 한국 음식명 발음
- 음식 가이드에 맞는 GUIDE·CAUTION 전달 방식

TTS에 음식 지식을 학습시키지는 않는다 — 지식은 DB로 관리하고 TTS는 발음·톤만 담당한다(환각 방지).

잠정 데이터 구성

항목	계획
화자	명시적으로 동의한 팀원 1명 (1일 차 동의서 작성)
총 문장	약 150문장 (음식 30개 대응)
총 음성 길이	약 25~35분
GUIDE / CAUTION	약 90문장 / 약 60문장
분할	학습·검증·테스트 = 80%·10%·10%
형식	WAV mono, 동일 샘플레이트, 동일 녹음 환경

웹 구조 — 배포 전략

우선순위	방식	설명
1안	Hugging Face Spaces + ZeroGPU	무료 GPU 추론 — Gradio 앱을 그대로 배포, 개인 컴퓨터가 꺼져도 서비스 유지
2안 (백업)	원격 데스크톱(RTX 3080Ti) 직접 서버	ZeroGPU가 우리 모델과 안 맞을 경우 — 단, 전원이 꺼지면 서비스도 중단됨(리스크)
3안 (보조)	Perso.ai (조 지급 유료 API)	메인 TTS 대체 아님 — Qwen3-TTS와 비교실험 재료, 또는 Avatar/립싱크 가산점 확장

- UI: Gradio (모바일 홈 화면 추가로 웹앱처럼 사용)
- 파이프라인/API: Python + FastAPI 또는 독립 모듈
- STT/OCR: 노트북 RTX 5060 또는 CPU
- Colab: 로컬 학습 실패 시 보조 실험 환경

외부 배포와 터널 연결은 실제 구현 전에 보안과 공개 범위를 별도로 확인한다.

입출력 계약

```
입력: {"image_path": "menu.jpg", "selected_food": "떡볶이", "question_audio_path": "question.webm"} 중간 결과:
{"detected_food": "떡볶이", "transcript": "Is it spicy?", "intent": "SPICY", "style": "CAUTION"} 출력:
{"answer_text": "Yes. Tteokbokki is usually spicy.", "answer_audio_path": "answer.wav", "latency_ms": 6500}
```

AC — 완료 기준

AC 1 · 음식 설명

Given 메뉴 이미지에서 비빔밥이 인식됐을 때, When 사용자가 음성으로 'What is this?'라고 질문하면, Then 비빔밥 설명 텍스트와 GUIDE 음성을 평균 7초 이내에 출력한다.

AC 2 · 맵기 질문

Given 떡볶이가 선택됐을 때, When 사용자가 음성으로 'Is it spicy?'라고 질문하면, Then SPICY 의도로 분류하고 CAUTION 음성으로 맵기 정보를 안내한다.

AC 3 · 미지원 음식

Given 등록되지 않은 음식이 인식됐을 때, When 설명을 요청하면, Then 사실을 추측하지 않고 미지원 안내를 출력한다.

AC 4 · 마이크 권한

Given 사용자가 마이크 권한을 거부했을 때, When 질문 단계에 진입하면, Then 텍스트 질문 버튼으로 동일한 기능을 사용할 수 있다.

AC 5 · 학습 효과

Given 동일 테스트 문장과 평가자 5명이 있을 때, When 기본·파인튜닝 모델을 비교하면, Then 음식명 발음 점수가 평균 0.4점 이상 향상되고 스타일 구분률이 85% 이상이어야 한다.

5. 고객 여정 맵

상황/단계	사용자 행동	생각/감정	Pain Point	서비스 개입
식당 방문	한글 메뉴판을 봄	무슨 음식인지 모르겠다	한글을 읽지 못함	메뉴 촬영
번역 시도	음식명을 번역	번역은 됐는데 어떤 음식이지?	직역으로 이해하기 어려움	음식명과 설명 연결
메뉴 탐색	음성으로 질문	맵거나 생소하면 어떡하지?	검색을 반복해야 함	영어 음성 질문(STT)
설명 확인	영어 설명을 들음	이제 알겠다	한국 음식명 발음이 어려움	파인튜닝 TTS
메뉴 결정	음식을 선택	안심·기대	정보 부족에 따른 부담	텍스트·음성 재확인

6. 4명 역할분담 청사진

STEP 1 · 문제와 목표

첫날에 영어권 관광객, 음식 30개, 질문 의도 유형(개발단계에 따라 조정), 스타일 2개, 평균 7초, 외부 LLM API 금지를 확정한다.

STEP 2 · 파이프라인 분해

- A. Vision/OCR
- B. STT
- C. 음식 DB·질문 분류
- D. TTS 파인튜닝·추론
- E. 웹앱 UI·통합·배포
- F. 평가·문서·발표

STEP 3 · 역할 배정

팀원	주 담당	보조 담당
하정운	TTS 모델 비교·파인튜닝·3080 Ti 관리	전체 파이프라인 설계
박민영	Vision/OCR·STT 파이프라인	5060 기반 성능 비교
배재훈	음식 DB·영어 설명·질문 분류·평가셋	사용성 테스트·문서
차백호	Gradio UI·FastAPI 통합·배포	오류 처리·데모 영상

TTS 파인튜닝이 가장 위험하므로 하정운 혼자 고립되지 않도록 박민영이 모델 비교와 실험 기록을 지원한다. 역할은 나누되, 파이프라인 전체는 팀원 모두가 함께 이해하는 것을 우선한다.

STEP 4 · Interface Contract

- OCR: 이미지 → 음식 후보 목록
- STT: 음성 → 영어 텍스트
- 분류: 텍스트 → 질문 의도
- DB: 음식+의도 → 영어 답변
- TTS: 영어 답변+스타일 → WAV
- UI: 전체 결과 표시·재생

STEP 5 · Mock 병렬 개발

- UI는 미리 만든 OCR·STT 결과 JSON으로 개발
- 질문 분류는 텍스트 입력으로 먼저 테스트
- OCR 담당자는 TTS 완성을 기다리지 않음
- TTS 담당자는 고정된 영어 문장으로 학습과 평가 진행

STEP 6 · 통합 테스트

정상 시나리오 8개, 예외 시나리오 6개, 음식별 최소 2개 이미지, 질문 유형별 최소 10개 음성, GPU 서버 장애, 마이크·카메라 권한 거부를 시험한다.

STEP 7 · 사용자 검증

팀 외부 사용자 5명 이상, TTS 청취 평가자 5명 이상에게 사용성과 음성 품질을 평가받고, 발견된 문제 중 최소 2개를 수정한다.

7. 14일 일정

일차	핵심 작업
1일	범위 고정, 저장소 구성, 역할·인터페이스 확정, 화자 동의서 작성
2일	Qwen3-TTS·XTTS 추론, 12GB 학습 가능성, 스타일 조건 기술검증
3일	음식 30개 DB·질문 데이터·메뉴 이미지 수집 (AI Hub 관광 음식메뉴판 데이터 신청·확보)
4일	영어 음성 녹음·전처리, OCR·STT 기본 파이프라인
5일	TTS 1차 학습, OCR 음식명 매칭, 질문 분류
6일	TTS 2차 실험, STT 비교 평가, UI Mock
7일	모듈별 중간 검증, 실패 기능 제거 결정
8일	Vision→STT→DB→TTS 1차 통합
9일	UI 연결, 오류 처리, 지연시간 측정
10일	TTS·STT 모델 비교, 표·그래프 작성
11일	외부 사용자 테스트 및 문제 수정
12일	배포 (HF Spaces·ZeroGPU 우선 시도), README, 라이선스·동의서 정리
13일	PPT·파이프라인 구조도·5분 데모 영상
14일	전체 리허설, 버그 수정, 제출물 최종 확인

7일 차 실패 판단 기준

TTS 파인튜닝 추론, 등록 음식 인식, 영어 질문 분류, 웹앱 음성 재생 중 하나라도 작동하지 않으면 범위를 축소한다.

- 음식 30개 → 15개
- OCR 자동 선택 → OCR 후 사용자가 음식 선택
- 질문 자유 발화 → 대표 문장 위주 인식
- GUIDE·CAUTION → GUIDE 한 스타일과 기본 모델 비교

TTS 파인튜닝과 STT/TTS 연결은 필수이므로 제거하지 않는다.

8. 주요 위험과 대응

위험	대응
Qwen3-TTS가 12GB에서 OOM	0.6B·gradient accumulation·checkpointing 검토, Colab 또는 XTTS 전환
영어 녹음 품질 불안정	한 명의 화자·동일 마이크·조용한 환경으로 통일
한국 음식명 발음 기준 모호	로마자 표기와 목표 발음을 사전 확정
메뉴 OCR 정확도 낮음	이미지 전처리·유사도 매칭·사용자 선택 보조
TTS가 7초 초과	문장을 1~2문장으로 제한하고 결과 캐싱
배포 GPU 연결 불안정	텍스트 우선 출력·재시도·상태 표시
정보 오류	검수된 JSON만 사용하고 자유 생성 금지
알레르기 책임	MVP에서 제외하고 식당 확인 안내 (향후 확장 로드맵으로 관리)
XTTS-v2 대체안 VRAM 부족	원격 데스크톱 OS(윈도우/리눅스) 확인 후 12GB로 충분한지 재검증, 부족하면 Colab 파인튜닝 경로로 전환
개인 컴퓨터 상시 서버화 시 중단 위험	1안 Hugging Face Spaces+ZeroGPU를 메인으로, 원격 데스크톱은 2안(백업)으로 이원화

9. 제출 체크리스트

제출 요건	MVP 계획
배포 URL	1안 HF Spaces+ZeroGPU 웹앱, 2안 원격 GPU 연결 웹앱
딥러닝 파인튜닝	TTS 모델 직접 학습
STT·TTS 포함	Faster-Whisper + 파인튜닝 TTS
소개 페이지	Gradio 소개 탭
GitHub 정리	모듈별 폴더·README·requirements
고객여정지도	본 문서에 포함
파이프라인 구조도	발표자료에 시각화
모델 비교	STT 2개·TTS 2개 (+Perso.ai 참고 비교)
음성 결과물	기본·파인튜닝·스타일별 샘플
데모 영상	5분 이내
PPT	결과와 비교 그래프 포함
Vision 가산점	메뉴 OCR (PaddleOCR)
사용성 테스트	외부 5명 이상
음성 데이터 동의	녹음 팀원 동의서 (1일 차 작성)
모델 라이선스	개발 1일 차 확인
LLM API 금지	런타임 미사용

10. 현재 판단

14일 안에 RTX 3080 Ti 12GB에서 파인튜닝 가능한 TTS 모델을 확정하고, GUIDE와 CAUTION의 차이를 실제 출력으로 증명할 수 있는지가 프로젝트의 핵심 기술 위험이다. 여기에 더해 배포 방식(무료 GPU 확보 여부)이 두 번째로 중요한 위험이다.

따라서 2일 차에 TTS 기술검증을 가장 먼저 수행한다. 이 검증 없이 음식 데이터부터 확대하면 일정이 무너질 수 있다.

- TTS 직접 학습
- STT 음성 입력
- 파인튜닝 전후 모델 비교
- 조건부 음성
- Vision 멀티모달
- 규칙 기반 의사결정
- 작동 가능한 웹앱 서비스 (1안 HF Spaces·ZeroGPU 확보 여부 조기 확인)
- 4명 병렬 작업과 사용성 평가